

# O jogador como token: um *set Transformer* sobre *freeze-frames* para estimativa de *Expected Goals*

Vinícius Siqueira<sup>1</sup>

<sup>1</sup>Centro de Matemática, Computação e Cognição  
Universidade Federal do ABC (UFABC) – Santo André, SP – Brasil

vinicius.siqueira.data@gmail.com

**Abstract.** *Expected Goals (xG) models estimate the probability that a shot results in a goal. Classical models rely on hand-crafted interaction features such as goalkeeper distance and the number of blockers. We ask whether a Transformer treating **each player as a token** learns this interaction geometry on its own. Over 99,746 shots with StatsBomb freeze-frames, we compare a ladder of models in which each rung adds exactly one capability. Pairwise attention improves probability quality (Brier  $-0.00056$ , 95% CI  $[-0.00081; -0.00031]$ , match-clustered paired bootstrap) but **not** ranking ability (AUC  $p = 0.797$ ). Attention maps show the model concentrating on blockers ( $2.76\times$  chance) and the goalkeeper ( $1.38\times$ ). We note explicitly that an “in the shot triangle” flag is itself a per-player input feature, so this shows the model weighting that cue, not re-discovering the geometry. A causal ablation confirms dependence: blocking the model from attending to blockers degrades Brier  $7.9\times$  more than suppressing the same number of random players. A capacity-matched Deep Sets (38,977 parameters) does not reproduce the gain, ruling out model size as the explanation. Under a competition-level hold-out (Premier League 2015/16, entirely unseen), every model loses about one fifth of its skill and the attention advantage is no longer established ( $p = 0.251$ ), while aggregate calibration stays within  $-0.6\%$ .*

**Resumo.** *Modelos de Expected Goals (xG) estimam a probabilidade de uma finalização terminar em gol. Os modelos clássicos dependem de atributos de interação desenhados à mão, como a distância do goleiro e o número de bloqueadores. Este trabalho investiga se um Transformer que trata **cada jogador como um token** aprende sozinho essa geometria de interação. Sobre 99.746 finalizações com freeze-frames da StatsBomb, compara-se uma escada de modelos em que cada degrau acrescenta exatamente uma capacidade. A atenção par a par melhora a qualidade da probabilidade (Brier  $-0,00056$ , IC 95%  $[-0,00081; -0,00031]$ , bootstrap pareado agrupado por partida), mas **não** a capacidade de ordenação (AUC,  $p = 0,797$ ). Os mapas de atenção mostram o modelo concentrando-se nos bloqueadores ( $2,76\times$  o acaso) e no goleiro ( $1,38\times$ ). Registra-se explicitamente que o indicador “dentro do triângulo do chute” é ele próprio um atributo de entrada por jogador, de modo que o resultado mostra o modelo ponderando essa pista, e não redescobrimo a geometria. Uma ablação causal confirma a dependência: proibir o modelo de observar os bloqueadores degrada o Brier 7,9 vezes mais do que suprimir a mesma quantidade de jogadores sorteados. Um Deep Sets com capacidade equiparada*

(38.977 parâmetros) não reproduz o ganho, o que afasta a explicação por tamanho. Sob hold-out por competição (Premier League 2015/16, inteiramente fora do treino), todos os modelos perdem cerca de um quinto da perícia e a vantagem da atenção deixa de ser estabelecida ( $p = 0,251$ ), enquanto a calibração agregada se mantém em  $-0,6\%$ .

## 1. Descrição do Problema

*Expected Goals* (xG) é hoje a métrica central da análise de futebol profissional: estima a probabilidade de uma finalização terminar em gol e permite avaliar desempenho para além do placar, que é um sinal ruidoso e de baixa frequência.

Os modelos clássicos de xG usam apenas atributos da própria finalização – distância, ângulo de visão da baliza, parte do corpo. Quando incorporam os demais jogadores, fazem-no por meio de atributos desenhados à mão: distância do goleiro, número de defensores na linha do chute, pressão sobre o chutador. Cada um desses atributos é uma hipótese humana sobre o que importa numa finalização.

Daí a pergunta que orienta este trabalho:

Um modelo que trata **cada jogador como um token** e usa *self-attention* aprende sozinho a geometria de interação que hoje exige engenharia manual de atributos?

A pergunta é interessante porque ambas as respostas são informativas. Se a resposta for afirmativa, a engenharia manual de atributos de interação torna-se dispensável. Se for negativa, isso indica que a informação relevante está *por jogador* e não *entre jogadores* – um resultado que contraria a intuição de que futebol é um jogo de interações.

### 1.1. Trabalhos relacionados

Modelos de xG baseados em atributos do chute e em atributos manuais de interação estão bem estabelecidos [Rathke 2017, Anzer and Bauer 2021, Mead et al. 2023, Iapteff et al. 2025], e Robberechts e Davis [Robberechts and Davis 2020] mostram como o volume de dados necessário cresce com a complexidade do modelo. O uso de aprendizado profundo sobre as posições de todos os jogadores também já foi explorado: Wang et al. [Wang et al. 2024] aplicam aprendizado geométrico sobre um grafo de jogadores em escanteios, e Fernández et al. [Fernández et al. 2021] avaliam o valor instantâneo da posse com redes profundas sobre dados de rastreamento.

Não foi localizado, contudo, trabalho revisado por pares que aplique *self-attention* sobre *freeze-frames* tratando cada jogador como um token para a estimativa de xG. É essa a lacuna que este trabalho explora.

### 1.2. Definição formal

Cada finalização é um par (cena, desfecho). A cena é um **conjunto** de até 22 jogadores, cada um descrito por um vetor de atributos geométricos; o desfecho é binário. O objetivo é aprender uma função que mapeia o conjunto em uma probabilidade no intervalo  $[0, 1]$ .

A propriedade que define o problema é a **invariância à permutação** [Zaheer et al. 2017, Lee et al. 2019]: a ordem em que os jogadores

são listados não carrega informação e, portanto, embaralhá-la não pode alterar a previsão. Isso distingue a tarefa de problemas sequenciais e justifica a ausência de *positional encoding* (Seção 2.3).

## 2. Abordagem

### 2.1. Dados

Utilizamos a StatsBomb Open Data [StatsBomb 2026], base pública sob licença de uso não comercial com atribuição. Para cada finalização, a base registra o *freeze-frame*: as coordenadas  $(x, y)$  de todos os jogadores visíveis no instante do chute, com seus papéis (companheiro, adversário, goleiro) e o desfecho do lance [StatsBomb 2021]. Após excluir pênaltis e lances sem *freeze-frame*, restam 99.746 finalizações de 3.961 partidas em 80 competições-temporada, com taxa de gol de 10,26%. A base foi baixada do ramo `master` em 03/07/2026; como esse ramo recebe novas competições ao longo do tempo, a data é parte da especificação do conjunto.

### Limitações declaradas dos dados

- O *freeze-frame* fornece **posição, mas não velocidade nem direção**. Um defensor parado e outro em corrida de recuperação são indistinguíveis para o modelo. A velocidade do chutador é atributo usado na literatura que dispõe de rastreamento [Anzer and Bauer 2021, Lucey et al. 2015], e está fora de alcance aqui.
- **30,7% das finalizações vêm de competições femininas** e cerca de 37% de apenas quatro temporadas 2015/16 de ligas europeias. Tratá-las conjuntamente não se justifica pela semelhança das taxas de gol (10,4% contra 10,2%) – taxa marginal igual não implica relação condicional igual. A justificativa é empírica e está na Seção 3.4: a conclusão do trabalho se mantém, com intervalo que não cruza zero, em cada um dos quatro recortes avaliados.
- A média é de **13,1 jogadores visíveis por cena**, não 22. O mascaramento das posições vazias é, portanto, o caso comum e não a exceção.

### 2.2. Representação: o jogador como token


Cada cena é convertida em um conjunto de até 22 tokens (o chutador e os jogadores do *freeze-frame*), cada um com 14 atributos: geometria absoluta, geometria **relativa ao chutador e à linha do chute** (projeção sobre a linha, distância perpendicular, presença no triângulo formado com os postes) e indicadores de papel.

A escolha dos atributos relativos é deliberada: eles informam a cada token sua própria relação com a finalização, sem codificar relações *entre* jogadores. Ambos os modelos recebem exatamente o mesmo tensor de entrada.

**Uma consequência dessa escolha precisa ser declarada.** Entre os 14 atributos está um indicador binário de que o jogador se encontra no triângulo formado pelo chutador e os postes – isto é, a informação “este jogador está no caminho do chute” **é fornecida ao modelo**, por jogador. Trata-se de uma relação entre o jogador, o chutador e a meta, calculada no pré-processamento e entregue pronta. Isso torna a comparação entre Deep Sets e Transformer mais conservadora do que aparenta: a geometria de obstrução está disponível aos dois, e o Deep Sets pode agregá-la por *pooling*. O que a atenção pode acrescentar é apenas a *ponderação contextual* dessa pista, não sua descoberta.

## 2.3. Arquitetura

*Encoder* Transformer [Vaswani et al. 2017] compacto: 2 camadas, 4 cabeças, dimensão 48, token [CLS], **sem *positional encoding*** e com máscara de *padding* nas posições sem jogador. Saída sigmoide. Implementação em PyTorch.



**Figura 1. Da cena ao xG. Cada jogador do *freeze-frame* torna-se um token de 14 atributos; um token aprendido [CLS] agrega a informação e alimenta a saída sigmoide. A ausência de *positional encoding* torna a previsão invariante a permutação dos jogadores.**

A Figura 1 resume o fluxo.

## 2.4. Protocolo experimental

**Escada de *baselines*.** Cada degrau acrescenta exatamente uma capacidade, de modo que a diferença entre degraus atribui o mérito a um componente específico:

**Tabela 1. Escada de modelos. Cada degrau acrescenta uma única capacidade.**

| Modelo                                              | O que acrescenta             |
|-----------------------------------------------------|------------------------------|
| B1 Regressão logística: distância, ângulo, cabeceio | o xG “de livro”              |
| B2 B1 + atributos manuais de interação              | interação <b>feita à mão</b> |
| DS Deep Sets [Zaheer et al. 2017] sobre os tokens   | informação por jogador       |
| TF Transformer sobre os mesmos tokens               | interação <b>aprendida</b>   |

**Os atributos do *baseline* B2 replicam a literatura de xG.** A distância e o ângulo de visão da baliza são os dois preditores clássicos, e sua combinação estima xG melhor do que cada um isoladamente [Rathke 2017]. A parte do corpo aparece em praticamente todos os modelos recentes [Anzer and Bauer 2021, Mead et al. 2023]. Os atributos de interação – distância do goleiro ao gol, se o goleiro está na linha do chute, número de defensores na trajetória e distância ao adversário mais próximo – são os mesmos adotados por Anzer e Bauer [Anzer and Bauer 2021] sobre dados posicionais sincronizados e por Iapteff et al. [Iapteff et al. 2025] sobre dados abertos da StatsBomb.

O paralelo com este último é direto: Iapteff et al. [Iapteff et al. 2025] selecionaram, por seleção sequencial, exatamente **sete** atributos, e o conjunto obtido coincide quase termo a termo com o do B2. Uma diferença é que a posição relativa do goleiro é aqui codificada de forma *contínua* (o desvio perpendicular em relação à linha chutador–gol), enquanto aquele trabalho usa um indicador binário – uma generalização do atributo consagrado.

Três atributos da literatura ficaram **de fora** do B2, e a omissão é declarada: o *padrão de jogo* (bola rolando, escanteio, falta), o *tipo de ação anterior* e o “melhor ângulo” livre de obstrução [Iapteff et al. 2025, Mead et al. 2023, Lucey et al. 2015]. Pênaltis foram excluídos da base, o que remove a principal fonte de heterogeneidade de situação. Como o B2 é um *baseline* de comparação e não a contribuição do trabalho, optou-se por mantê-lo alinhado ao conjunto de atributos puramente geométricos, que é o mesmo espaço de informação disponível aos modelos neurais – caso contrário a comparação deixaria de ser justa.

A comparação decisiva na Tabela 1 é **TF contra DS**: ambos recebem exatamente os mesmos tokens, e apenas o Transformer pode comparar jogadores entre si.

**Duas ressalvas sobre o quanto a escada de fato isola.** Primeira: o Transformer possui **38.737** parâmetros contra **10.273** do Deep Sets – 3,8 vezes mais –, de modo que a diferença entre os dois não isola a atenção, mas sim “atenção mais capacidade”. Um controle com Deep Sets de capacidade equiparada foi conduzido e é apresentado na Seção 3.4. Segunda: o degrau B2→DS acrescenta simultaneamente a *cena completa* e a *não-linearidade*, pois o B2 é linear. Parte do salto atribuído à representação por token é, portanto, atribuível apenas à classe de modelo, e a separação exigiria um *baseline* não-linear sobre os mesmos sete atributos manuais.

**Divisão dos dados por partida** (70/15/15). Finalizações da mesma partida compartilham time, adversário e contexto tático; separá-las entre treino e teste inflaria as métricas por vazamento.

**Métricas.** AUC (ordenação), *log loss*, **Brier score** [Brier 1950] e **curva de calibração** [Niculescu-Mizil and Caruana 2005] (qualidade da probabilidade). Como *xG* é uma probabilidade e não um *ranking*, o Brier é a métrica de decisão; a AUC a acompanha para distinguir “ordena bem” de “acerta o valor”.

**Significância.** As diferenças entre modelos são avaliadas por *bootstrap* pareado **agrupado por partida**: reamostram-se partidas, não finalizações, porque chutes do mesmo jogo são correlacionados e reamostrá-los individualmente produziria intervalos de confiança estreitos demais.

### 3. Resultados

#### 3.1. Escada de *baselines*


A Tabela 2 apresenta o desempenho dos quatro modelos. Cada degrau acrescenta uma única capacidade, de modo que a diferença entre linhas consecutivas atribui o mérito a um componente específico.

A Figura 2 torna o padrão visível. Fornecer a cena inteira ao modelo supera resumi-la em atributos manuais – mas **menos do que a comparação com o B2 linear sugere**. O B2-GBM, que usa exatamente os mesmos sete atributos manuais e difere apenas na classe de modelo, alcança AUC 0,8069 e Brier 0,07710. Da distância entre o B2 e o Deep Sets, a **não-linearidade sozinha explica 54,5 % em AUC e 64,6 % em Brier**.

A representação por token, portanto, agrega valor real, porém aproximadamente *metade* do que uma escada iniciada em um *baseline* linear indicaria. Registre-se ainda que o B2-GBM é o **modelo mais bem calibrado do estudo** (ECE 0,0018): um *gradient*

**Tabela 2. Desempenho no conjunto de teste (14.935 finalizações), divisão por partida. Modelos neurais: combinação de 5 sementes. ECE = erro de calibração esperado, em decis de xG previsto. B2-GBM usa os mesmos sete atributos do B2, mudando apenas a classe de modelo.**

| Modelo                                | AUC           | Brier          | ECE           |
|---------------------------------------|---------------|----------------|---------------|
| B1 – logística                        | 0,7653        | 0,08237        | 0,0076        |
| B2 – logística + interação            | 0,7961        | 0,07846        | 0,0035        |
| B2-GBM – mesmos atributos, não-linear | 0,8069        | 0,07710        | <b>0,0018</b> |
| DS – Deep Sets (tokens)               | 0,8160        | 0,07635        | 0,0070        |
| TF – Transformer (tokens)             | <b>0,8162</b> | <b>0,07579</b> | 0,0043        |



**Figura 2. Desempenho dos cinco modelos. Optou-se por marcadores em vez de barras porque as AUCs ocupam a faixa estreita entre 0,76 e 0,82: barras a partir da origem tornariam as diferenças invisíveis, e barras truncadas distorceriam a proporção.**

*boosting* sobre sete atributos construídos manualmente entrega a melhor calibração entre todos os modelos avaliados.


### 3.2. Calibração

A Tabela 2 revela um padrão que a AUC isoladamente esconde: **os dois *baselines* de atributos manuais são os mais bem calibrados do conjunto** (ECE 0,0018 no B2-GBM e 0,0035 no B2), apesar de terem Brier pior que os modelos neurais. Estes apresentam Brier melhor e calibração pior.

Não há contradição. O Brier decompõe-se em *calibração* – as probabilidades correspondem às frequências observadas? – e *refinamento* – o modelo separa bem os casos? Os modelos neurais vencem no refinamento e perdem na calibração, com saldo positivo. A Figura 3 mostra as quatro curvas.

#### A recalibração não ajuda

Diante da diferença de ECE entre o B2 e os modelos neurais, testou-se recalibrar as saídas por *Platt scaling* e por regressão isotônica, ajustando o calibrador no conjunto



**Figura 3. Curva de calibração e Brier score. À esquerda, a frequência observada de gol contra o xG previsto, por decil.**

de **validação** e avaliando no de teste – ajustá-lo no teste reproduziria o vazamento que a divisão por partida existe para evitar.

**Tabela 3. Efeito da recalibração. Calibrador ajustado na validação, avaliação no teste, semente 0.**

| Modelo | Variante       | Brier          | ECE           |
|--------|----------------|----------------|---------------|
| DS     | sem calibração | <b>0,07653</b> | 0,0069        |
| DS     | Platt          | 0,07652        | <b>0,0055</b> |
| DS     | isotônica      | 0,07682        | 0,0065        |
| TF     | sem calibração | <b>0,07612</b> | 0,0076        |
| TF     | Platt          | 0,07613        | 0,0069        |
| TF     | isotônica      | 0,07633        | <b>0,0057</b> |

O resultado é negativo: o *Platt scaling* é neutro em Brier e a regressão isotônica o *piora* em ambos os modelos. Com evento raro e 15 mil pontos de validação, a flexibilidade da isotônica ajusta-se a ruído que não se repete no teste. Ambas reduzem modestamente o ECE, devolvendo em refinamento o que ganham em calibração.

A explicação é que os modelos já saem calibrados: a entropia cruzada é uma regra de pontuação própria, de modo que otimizá-la já posiciona as probabilidades na escala correta [Niculescu-Mizil and Caruana 2005]. Os resultados reportados neste trabalho são, portanto, do modelo **sem recalibração**.

## Calibração agregada por partida

O teste mais próximo do uso real da métrica não é por finalização, e sim por partida: somando o xG previsto de todos os chutes de um jogo, o total corresponde aos gols efetivamente marcados?

Sobre as 595 partidas de teste, o Transformer prevê **1591,2** de xG total contra **1571** gols observados – viés de **+1,3 %**. O Deep Sets fica em **+1,5 %**. O erro médio de 1,16 gol *por partida* não indica falha do modelo: uma partida tem poucos gols e forte

componente aleatório, e é precisamente por isso que o xG é uma métrica de agregação. O diagrama por partida, disponível no repositório, mostra o padrão esperado: a média por faixa acompanha a diagonal na região densa e regride ao centro nos extremos, onde há poucas partidas.

### 3.3. A atenção acrescenta algo? (questão central)

Deep Sets e Transformer recebem exatamente os mesmos tokens; apenas o segundo compara jogadores entre si. A diferença entre eles isola o valor da atenção par a par. Foram treinadas 5 sementes de cada modelo, com seleção por Brier de validação.

**Tabela 4. Transformer contra Deep Sets, 5 sementes cada. Teste pareado por *bootstrap* agrupado por partida (2.000 reamostras).**

|                                                             | Brier                        | AUC                        |
|-------------------------------------------------------------|------------------------------|----------------------------|
| <i>Modelos individuais</i> (média $\pm$ dp das 5 sementes)  |                              |                            |
| DS                                                          | 0,07655 $\pm$ 0,00007        | <b>0,8146</b> $\pm$ 0,0007 |
| TF                                                          | <b>0,07624</b> $\pm$ 0,00005 | 0,8141 $\pm$ 0,0009        |
| Diferença (TF – DS)                                         | –0,00031                     | –0,00058                   |
| <i>Combinação das 5 sementes</i> (média das probabilidades) |                              |                            |
| DS                                                          | 0,07635                      | 0,8160                     |
| TF                                                          | <b>0,07579</b>               | <b>0,8162</b>              |
| Diferença (TF – DS)                                         | –0,00056                     | +0,00024                   |
| IC 95% (partidas)                                           | [–0,00081; –0,00031]         | [–0,00148; +0,00199]       |
| valor- <i>p</i>                                             | < 0,001                      | 0,797                      |

A Tabela 4 apresenta o resultado, que é uma dissociação limpa entre as duas métricas:

**A atenção par a par melhora a qualidade da probabilidade, mas não a capacidade de ordenar as finalizações.**

O sinal favorece o Transformer em Brier nas cinco sementes, e a distribuição *bootstrap* da diferença entre as combinações situa-se integralmente à esquerda de zero. Em AUC a diferença é indistinguível de ruído ( $p = 0,797$ ) e, entre modelos individuais, favorece o *Deep Sets*.

**Três ressalvas impedem tratar o efeito como estabelecido.**

Primeira, **o teste condiciona em uma combinação específica de sementes**. Ele reamostra partidas, propagando a variabilidade dos dados, mas não a variabilidade de *inicialização*. A diferença entre modelos individuais (–0,00031) é pouco mais da metade da diferença entre as combinações (–0,00056): parte do efeito anunciado é o Transformer beneficiar-se mais da média de sementes – suas previsões são mais dispersas entre inicializações –, e não a atenção. Refazendo o mesmo teste **semente a semente**, o intervalo de confiança cruza zero nas **cinco** inicializações (menor valor-*p*: 0,053). A significância, portanto, existe para o conjunto combinado, não para um modelo individual. Em contrapartida, o sinal favorece o Transformer em 5 de 5 sementes, o que sob um teste de sinal corresponderia a  $p \approx 0,06$ : sugestivo, e coerente com um efeito real porém pequeno demais para ser detectado por uma única inicialização com 595 partidas.

Segunda, **o mecanismo alegado depende do recorte**. Na combinação das sementes o Transformer é o mais bem calibrado (ECE 0,0043 contra 0,0070); nos modelos individuais a ordem *inverte* (0,0082 contra 0,0074). Atribuir o ganho à calibração é, portanto, sustentável apenas para o conjunto combinado.

Terceira, **a magnitude é pequena**. Tomando a taxa média de gol como referência trivial, o Brier de referência no teste é 0,0941; a perícia do Deep Sets sobre essa referência é de 18,9 % e a do Transformer, 19,5 %. A atenção acrescenta cerca de meio ponto percentual de perícia – aproximadamente 3 % da capacidade preditiva do modelo. O efeito é direcionalmente consistente, mas sua relevância prática é discutível.

Some-se a isso a diferença de capacidade declarada na Seção 2.4: o resultado honesto é que **a atenção, somada a 3,8 vezes mais parâmetros, produz um ganho pequeno e consistente na qualidade da probabilidade, e nenhum na ordenação**.

### 3.4. O ganho é atenção ou capacidade?

O Transformer possui 3,8 vezes os parâmetros do Deep Sets, de modo que a comparação anterior não isola a atenção. Para separar os dois efeitos, treinou-se um Deep Sets com dimensão 96, que totaliza **38.977** parâmetros contra 38.737 do Transformer – equiparação de 100,6 % –, sob protocolo idêntico e com as mesmas cinco sementes.

**Tabela 5. Controle de capacidade. Cinco sementes por modelo; *bootstrap* pareado agrupado por partida.**

| Modelo                                                      | Parâmetros | Brier                    | AUC                     |
|-------------------------------------------------------------|------------|--------------------------|-------------------------|
| DS original (dim 48)                                        | 10.273     | 0,07655 ± 0,00008        | <b>0,8146</b> ± 0,0007  |
| DS largo (dim 96)                                           | 38.977     | 0,07670 ± 0,00005        | 0,8131 ± 0,0010         |
| TF (dim 48)                                                 | 38.737     | <b>0,07624</b> ± 0,00006 | 0,8141 ± 0,0011         |
| <i>Diferenças de Brier entre combinações das 5 sementes</i> |            |                          |                         |
| TF – DS largo                                               |            | –0,00073                 | IC [–0,00101; –0,00045] |
| TF – DS original                                            |            | –0,00056                 | IC [–0,00081; –0,00031] |
| DS largo – DS original                                      |            | +0,00018                 | IC [+0,00002; +0,00034] |

A Tabela 5 **refuta** a explicação por capacidade. Equiparar os parâmetros não aproximou o Deep Sets do Transformer: afastou. A vantagem do Transformer *cresce* de –0,00056 para –0,00073 quando a comparação se torna justa, e o intervalo de confiança não cruza zero.

Há ainda um achado próprio: **ampliar a capacidade do Deep Sets o piora** (+0,00018 de Brier, com intervalo estritamente positivo). Sem o mecanismo de atenção, os parâmetros adicionais não encontram estrutura a explorar e o modelo sobreajusta.

### Tampouco é a ReLU terminal do Deep Sets

Resta uma explicação arquitetural que não envolve atenção. O  $\phi$  do Deep Sets *termina* em ReLU, de modo que toda representação por jogador é não negativa e a cabeça linear recebe um vetor restrito ao ortante positivo; a saída do [CLS] vem do fluxo residual e tem

sinal livre. Se fosse essa a origem da diferença, a comparação estaria medindo “atenção mais liberdade de sinal” – e o controle de capacidade não a detectaria, pois ampliar a dimensão não remove a restrição. Treinou-se então um Deep Sets idêntico *exceto* pela remoção dessa ReLU, com os mesmos 10.273 parâmetros e as mesmas três sementes, usadas também para refazer as combinações de referência.

**A remoção não aproximou o Deep Sets do Transformer: piorou-o.** O Brier médio passa de 0,07654 para 0,07664 e a AUC cai de 0,8145 para 0,8131, com as três sementes na mesma direção nas duas métricas. Entre as combinações, a diferença de Brier é de +0,00012, IC  $[-0,00008; +0,00032]$  – sem indício de ganho –, enquanto a vantagem do Transformer permanece com intervalo estritamente negativo ( $-0,00067$ , IC  $[-0,00095; -0,00040]$ ). A restrição de sinal não explica a diferença entre as arquiteturas.

### A conclusão vale em todos os recortes

A vantagem do Transformer foi reavaliada em quatro subconjuntos do teste, e em nenhum o intervalo de confiança cruza zero: futebol feminino ( $-0,00086$ , 4.443 finalizações), futebol masculino ( $-0,00043$ , 10.492), temporadas 2015/16 ( $-0,00053$ , 6.070) e demais competições ( $-0,00058$ , 8.865). O efeito é cerca de duas vezes maior no futebol feminino, o que se registra sem investigar.

### 3.5. Generalização para uma competição não vista

Os quatro recortes acima provêm do mesmo conjunto de 80 competições-temporada: medem robustez interna, não generalização para um torneio não observado. Para medir esta última, a *Premier League* 2015/16 foi retirada por inteiro do treino e da validação e usada como teste – 9.817 finalizações em 380 partidas, com 914 gols –, com asserção no código de que nada vazou.

O Brier não é comparável entre os dois testes, porque depende da taxa de gol do conjunto: a competição retirada tem 9,31 % de gols contra 10,52 % do teste habitual, de modo que qualquer modelo obtém Brier mais baixo nela. A comparação usa portanto a **perícia** sobre a taxa média de gol,  $1 - \text{Brier}/[p(1 - p)]$ , que é adimensional.

**Tabela 6. Generalização para a *Premier League* 2015/16, inteiramente fora do treino. “Dentro” é o teste habitual, de partidas sorteadas.**

| Modelo      | Perícia       |               | AUC           |        |
|-------------|---------------|---------------|---------------|--------|
|             | Dentro        | Fora          | Dentro        | Fora   |
| B1          | 12,5 %        | 9,3 %         | 0,7653        | 0,7553 |
| B2          | 16,6 %        | 13,1 %        | 0,7961        | 0,7838 |
| Deep Sets   | 18,9 %        | 15,2 %        | 0,8160        | 0,7981 |
| Transformer | <b>19,5 %</b> | <b>15,5 %</b> | <b>0,8162</b> | 0,7969 |

A Tabela 6 sustenta três leituras.

Primeira, **todos os modelos perdem cerca de um quinto da perícia** fora da distribuição, e em proporção semelhante: nenhuma arquitetura se mostra especialmente frágil, mas os números das seções anteriores são otimistas para uma liga-temporada nova.

Segunda, **a calibração agregada não se degrada**. O xG somado do Transformer é de 908,7 contra 914 gols observados – viés de  $-0,6\%$ , melhor do que o  $+1,3\%$  obtido dentro da distribuição. O modelo perde capacidade de *ordenar* finalizações de uma liga que não viu, e mantém a de estimar *quanto* vale o conjunto delas, que é o uso mais comum do xG.


Terceira, **a vantagem do Transformer não se sustenta fora da distribuição**:  $-0,00024$ , IC  $[-0,00063; +0,00016]$ ,  $p = 0,251$ . Duas explicações são compatíveis, e este trabalho não decide entre elas: o efeito pode ter encolhido (de  $-0,00056$  para  $-0,00024$ ) ou o teste pode ter perdido poder, já que 9.817 finalizações são dois terços das 14.935 do teste habitual. Registre-se que aqui o Transformer foi treinado com duas sementes e não três – a máquina suspendia durante a madrugada e o tempo de parede inviabilizou a terceira. É a única assimetria de protocolo do trabalho, e favorece o Deep Sets.

### 3.6. O que a atenção está olhando

O resultado anterior mostra *que* a atenção contribui. Resta saber *como*. Mediu-se a atenção que o token [CLS] dirige a cada jogador, normalizada pela atenção que ele receberia sob distribuição uniforme: o valor 1,0 indica “observado como um jogador qualquer da cena”.

**Tabela 7. Razão de atenção por papel na cena. Transformer, semente 0, média das 2 camadas e 4 cabeças, sobre 14.935 finalizações.**

| Papel na cena                             | Razão média  | Mediana |
|-------------------------------------------|--------------|---------|
| Bloqueador (adversário na linha do chute) | <b>2,76x</b> | 2,45x   |
| Goleiro adversário                        | <b>1,38x</b> | 1,21x   |
| Outro adversário                          | 0,92x        | 0,96x   |
| Companheiro                               | 0,75x        | 0,74x   |



**Figura 4. Para quem o token [CLS] olha. A linha vertical marca a atenção que um jogador receberia por acaso.**

O ordenamento da Tabela 7, visível na Figura 4 – bloqueador, goleiro, adversário distante, companheiro – reproduz a hierarquia que a literatura de xG codifica manualmente.

**É preciso ser preciso sobre o que isso demonstra.** Como declarado na Seção 2.2, o indicador “dentro do triângulo do chute” é **um atributo de entrada**, fornecido por jogador. O modelo não descobriu quem está no caminho do chute: essa informação lhe foi dada. O que a Tabela 7 mostra é que o modelo aprendeu a **ponderar** essa pista – atribuindo peso 2,76 vezes maior a quem a possui –, em vez de tratar todos os jogadores como igualmente relevantes. É um resultado mais modesto do que “a atenção redescobriu a geometria de interação”, e é o que os dados sustentam.

Isso também oferece a explicação mais econômica para o Deep Sets igualar o Transformer em ordenação: se a geometria de obstrução chega pronta em cada token, um agregador por *pooling* já a aproveita, e resta pouco para a atenção acrescentar.

Três ressalvas adicionais. A análise é **correlacional**: mostra onde a atenção se concentra, não que dela decorra o ganho em Brier. Os pesos da segunda camada operam sobre representações já contextualizadas, de modo que “atenção alta” não equivale a “importância” – ponto amplamente discutido na literatura sobre atenção como explicação. E os valores provêm de **uma única semente**, com média sobre 2 camadas e 4 cabeças, o que pode cancelar papéis distintos. A média sobre 2 camadas e 4 cabeças pode cancelar papéis distintos entre elas.

## Ablação causal

Para ir além da correlação, a atenção que o [CLS] dirige a um grupo foi **suprimida** – zerada e com a linha renormalizada, de modo que o modelo continua vendo uma distribuição válida, porém proibido de observar aqueles jogadores. Mede-se então a degradação do Brier. O controle é essencial: suprimir jogadores sempre causa alguma perda, e a pergunta é se suprimir *estes* causa mais.

**Tabela 8. Ablação da atenção do [CLS]. Transformer, semente 0, 14.935 finalizações.**

| Grupo suprimido                              | Brier   | $\Delta$ vs. intacto | AUC           |
|----------------------------------------------|---------|----------------------|---------------|
| nenhum (referência)                          | 0,07612 | —                    | 0,8159        |
| <b>Bloqueadores</b>                          | 0,07701 | <b>+0,00088</b>      | <b>0,8064</b> |
| Goleiro                                      | 0,07671 | +0,00059             | 0,8145        |
| <i>Controle:</i> sorteados, mesma quantidade | 0,07624 | +0,00011             | 0,8148        |
| Companheiros                                 | 0,07618 | +0,00005             | 0,8153        |
| Todos os jogadores                           | 0,10194 | +0,02582             | 0,7951        |

Na Tabela 8, suprimir os bloqueadores custa +0,00088 de Brier – **7,9 vezes** o custo de suprimir a mesma quantidade de jogadores sorteados (+0,00011). A AUC cai de 0,8159 para 0,8064, contra 0,8148 no controle. A evidência, portanto, **não é apenas correlacional**: o desempenho depende causalmente dessa atenção.


Dois aspectos reforçam a leitura. O efeito (+0,00088) é *maior* que a própria vantagem do Transformer sobre o Deep Sets equiparado (0,00073), o que indica mecanismo estruturante e não marginal. E companheiros custam praticamente nada (+0,00005) – coerente, pois em uma finalização quem obstrui são os adversários.

Permanece a limitação de **uma única semente**, a única cujos pesos foram preservados, e a supressão atua nas duas camadas simultaneamente.

### 3.7. Estudo de caso: Eurocopa 2024

A proposta deste trabalho previa a Copa do Mundo de 2026 como estudo de caso. Em consulta à StatsBomb Open Data em 09/08/2026 verificou-se que a competição ainda não havia sido publicada – a mais recente disponível é a Eurocopa Feminina de 2025. O estudo de caso foi então conduzido sobre a **Eurocopa 2024**, o torneio de seleções mais recente da base.

Utilizaram-se apenas as 166 finalizações do torneio que caíram no conjunto de **teste** (6 partidas, 15 gols). Trata-se de **análise qualitativa**, não de avaliação: 15 gols é amostra pequena demais para sustentar conclusão quantitativa, papel que cabe à Seção anterior.



**Figura 5. Três cenas reais da Eurocopa 2024. O tamanho de cada jogador é proporcional à atenção que o token [CLS] lhe dirige. Os casos foram selecionados por critério automático, não manualmente.**

Os três casos da Figura 5 mostram o modelo **deslocando o foco conforme a cena** – ponderando de modo distinto jogadores que recebem os mesmos tipos de atributo. No chute de fora da área com o goleiro na trajetória, o goleiro concentra sozinho 32 % de toda a atenção dirigida aos jogadores, e o xG previsto é 0,035. Na finalização dentro da área com defensores atravessados, a atenção migra para os bloqueadores (49 %) e o goleiro cai para 5 %; apesar da proximidade da meta, o xG é de apenas 0,117. No lance de maior xG do torneio (0,750), dentro da pequena área e sem obstrução, a atenção *dispersa-se*: nenhum jogador é determinante porque nada interfere na trajetória.

O contraste entre o segundo e o terceiro casos resume o argumento do trabalho em uma imagem: mesma região do campo, xG seis vezes menor, e a diferença é visível na distribuição da atenção.

## 4. Lições Aprendidas

### 4.1. O que funcionou

**Escalar os dados resolveu o que aparentava ser um problema de arquitetura.** Na prova de conceito, com 6.347 finalizações, os modelos neurais alcançavam AUC de aproximadamente 0,71 – *abaixo* do *baseline* com atributos manuais (0,736). Com 99.746

finalizações, ambos superam esse *baseline* com folga. A conclusão precipitada de que “a arquitetura não serve” teria sido incorreta.

**A escolha da métrica alterou a conclusão científica.** A implementação inicial reportava apenas AUC. Sob essa métrica, o Transformer é ligeiramente *pior* que o Deep Sets, e a conclusão seria que a atenção não contribui – um resultado negativo falso. Foi a adoção do Brier como critério de decisão, motivada pelo fato de xG ser uma probabilidade e não um ordenamento, que tornou o efeito visível. Uma decisão metodológica, tomada antes dos experimentos, determinou o que se pôde concluir.

## 4.2. O que não funcionou

**Trocar a métrica de seleção sem reescalar a tolerância.** Ao migrar o critério de parada antecipada de AUC para Brier, manteve-se o limiar de melhoria em  $10^{-6}$  absoluto. Como a AUC opera em torno de 0,81 e o Brier em torno de 0,076, o mesmo valor absoluto tornou-se relativamente dez vezes mais restritivo: praticamente qualquer flutuação era contabilizada como melhoria, a paciência não era acionada e o treino prosseguia até a última época, selecionando um estado já sobreajustado. O critério concebido para otimizar o Brier produziu Brier *pior* (0,07646 contra 0,07627 na mesma semente). A correção para tolerância relativa recuperou o desempenho e reduziu o tempo de treino em cerca de 30%.

**Recalibrar não melhorou nada.** Ao observar que o *baseline* de regressão logística apresentava melhor ECE que os modelos neurais, previu-se que recalibrar traria ganho fácil em Brier. Não trouxe: o *Platt scaling* foi neutro e a regressão isotônica piorou o Brier dos dois modelos (Tabela 3). A hipótese estava errada, e a razão é instrutiva – treinar com entropia cruzada já produz probabilidades calibradas, restando pouco a corrigir.

**Duas sementes não bastam, e a estabilidade aparente engana.** Com 2 sementes, o Deep Sets apresentou amplitude de AUC de 0,0001, sugerindo extraordinária estabilidade. Com 5 sementes, a amplitude foi de 0,0019 – dezenove vezes maior – e a conclusão sobre sobreposição de faixas, obtida com a amostra menor, mostrou-se equivocada.

**Afirmar que o modelo redescobriu algo que eu havia lhe fornecido.** A primeira versão deste relatório sustentava que a concentração de atenção sobre os bloqueadores demonstrava redescoberta autônoma da geometria de interação, “sem jamais ter recebido essa informação como atributo”. A afirmação é **falsa**: o indicador de presença no triângulo do chute é o décimo atributo de cada token. O erro sobreviveu a uma verificação automática que confere cada número do texto contra o registro do experimento que o produziu – porque essa verificação garante que os números estão *transcritos* corretamente, não que estão sendo *interpretados* corretamente. Nenhuma automação substitui a leitura crítica do próprio código.

**A escada isolava menos do que eu afirmava.** O Transformer tem 3,8 vezes mais parâmetros que o Deep Sets, e o degrau B2→DS mistura representação com não-linearidade. Ambos os confundimentos estavam presentes desde o desenho do protocolo e só foram percebidos na revisão final. O primeiro foi então medido (Seção 3.4) e revelou-se favorável à conclusão – mas isso é sorte, não método: se a capacidade explicasse o efeito,

o trabalho teria sustentado por semanas uma conclusão infundada. O controle deveria ter sido parte do desenho, não da correção.

### 4.3. O que eu faria diferente

Verificaria a disponibilidade dos dados antes de prometé-los: a proposta previa a Copa do Mundo de 2026 como estudo de caso, mas a competição não havia sido publicada na base pública até a data de entrega. Registraria previsões e pesos dos modelos em disco desde o primeiro experimento – sua ausência obrigou a retreinamentos que consumiram horas. E adotaria as métricas de calibração desde o início, em vez de reportar AUC e descobrir tardiamente que ela é cega justamente para a dimensão que define o problema.

### Disponibilidade do código

Todo o código, a documentação de decisões e o registro de experimentos estão em <https://github.com/vinisique/xg-set-transformer>.

### Referências

- Anzer, G. and Bauer, P. (2021). A goal scoring probability model for shots based on synchronized positional and event data in football (soccer). *Frontiers in Sports and Active Living*, 3:624475.
- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3.
- Fernández, J., Bornn, L., and Cervone, D. (2021). A framework for the fine-grained evaluation of the instantaneous expected value of soccer possessions. *Machine Learning*, 110(6):1389–1427.
- Iapteff, L., Le Coz, S., Rioland, M., Houde, T., Carling, C., and Imbach, F. (2025). Toward interpretable expected goals modeling using Bayesian mixed models. *Frontiers in Sports and Active Living*, 7:1504362.
- Lee, J., Lee, Y., Kim, J., Kosiorek, A. R., Choi, S., and Teh, Y. W. (2019). Set transformer: A framework for attention-based permutation-invariant neural networks. In *International Conference on Machine Learning (ICML)*.
- Lucey, P., Bialkowski, A., Monfort, M., Carr, P., and Matthews, I. (2015). “Quality vs Quantity”: Improved shot prediction in soccer using strategic features from spatiotemporal data. In *Proceedings of the 9th Annual MIT Sloan Sports Analytics Conference*.
- Mead, J., O’Hare, A., and McMenemy, P. (2023). Expected goals in football: Improving model performance and demonstrating value. *PLOS ONE*, 18(4):e0282295.
- Niculescu-Mizil, A. and Caruana, R. (2005). Predicting good probabilities with supervised learning. In *International Conference on Machine Learning (ICML)*.
- Rathke, A. (2017). An examination of expected goals and shot efficiency in soccer. *Journal of Human Sport and Exercise*, 12(Proc2).
- Robberechts, P. and Davis, J. (2020). How data availability affects the ability to learn good xG models. In *Machine Learning and Data Mining for Sports Analytics (MLSA)*, Communications in Computer and Information Science, pages 17–27. Springer.

- StatsBomb (2021). StatsBomb data case studies: Freeze frames and defender locations.
- StatsBomb (2026). Statsbomb open data. <https://github.com/statsbomb/open-data>. Acesso em 09 ago. 2026.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Wang, Z., Veličković, P., Hennes, D., Tomašev, N., Prince, L., Kaisers, M., Bachrach, Y., and Elie, R. (2024). TacticAI: an AI assistant for football tactics. *Nature Communications*, 15(1):1906.
- Zaheer, M., Kottur, S., Ravanbakhsh, S., Póczos, B., Salakhutdinov, R., and Smola, A. J. (2017). Deep sets. In *Advances in Neural Information Processing Systems (NeurIPS)*.