

O jogador como token: um *set Transformer* sobre *freeze-frames* para estimativa de *Expected Goals*

Vinícius Siqueira¹

¹Centro de Matemática, Computação e Cognição
Universidade Federal do ABC (UFABC) – Santo André, SP – Brasil

vinicius.siqueira.data@gmail.com

Abstract. *Expected Goals (xG) models estimate the probability that a shot results in a goal. Classical models rely on hand-crafted interaction features such as goalkeeper distance and the number of blockers. We ask whether a Transformer treating **each player as a token** learns this interaction geometry on its own. Over 99,746 shots with StatsBomb freeze-frames, we compare a ladder of models in which each rung adds exactly one capability. Pairwise attention improves probability quality (Brier -0.00056 , 95% CI $[-0.00081; -0.00031]$, match-clustered paired bootstrap) but **not** ranking ability (AUC $p = 0.797$). Attention maps show the model concentrating on blockers ($2.76\times$ chance) and the goalkeeper ($1.38\times$). We note explicitly that an “in the shot triangle” flag is itself a per-player input feature, so this shows the model weighting that cue, not re-discovering the geometry. A causal ablation confirms dependence: blocking the model from attending to blockers degrades Brier $7.9\times$ more than suppressing the same number of random players. A capacity-matched Deep Sets (38,977 parameters) does not reproduce the gain, ruling out model size as the explanation. Under a competition-level hold-out (Premier League 2015/16, entirely unseen), every model loses about one fifth of its skill and the attention advantage is no longer established ($p = 0.251$), while aggregate calibration stays within -0.6% .*

Resumo. *Modelos de Expected Goals (xG) estimam a probabilidade de uma finalização terminar em gol. Os modelos clássicos dependem de atributos de interação desenhados à mão, como a distância do goleiro e o número de bloqueadores. Este trabalho investiga se um Transformer que trata **cada jogador como um token** aprende sozinho essa geometria de interação. Sobre 99.746 finalizações com freeze-frames da StatsBomb, compara-se uma escada de modelos em que cada degrau acrescenta exatamente uma capacidade. A atenção par a par melhora a qualidade da probabilidade (Brier $-0,00056$, IC 95% $[-0,00081; -0,00031]$, bootstrap pareado agrupado por partida), mas **não** a capacidade de ordenação (AUC, $p = 0,797$). Os mapas de atenção mostram o modelo concentrando-se nos bloqueadores ($2,76\times$ o acaso) e no goleiro ($1,38\times$). Registra-se explicitamente que o indicador “dentro do triângulo do chute” é ele próprio um atributo de entrada por jogador, de modo que o resultado mostra o modelo ponderando essa pista, e não redescobrimo a geometria. Uma ablação causal confirma a dependência: proibir o modelo de observar os bloqueadores degrada o Brier 7,9 vezes mais do que suprimir a mesma quantidade de jogadores sorteados. Um Deep Sets com capacidade equiparada*

(38.977 parâmetros) não reproduz o ganho, o que afasta a explicação por tamanho. Sob hold-out por competição (Premier League 2015/16, inteiramente fora do treino), todos os modelos perdem cerca de um quinto da perícia e a vantagem da atenção deixa de ser estabelecida ($p = 0,251$), enquanto a calibração agregada se mantém em $-0,6\%$.

1. Descrição do Problema

Expected Goals (xG) é hoje a métrica central da análise de futebol profissional: estima a probabilidade de uma finalização terminar em gol e permite avaliar desempenho para além do placar, que é um sinal ruidoso e de baixa frequência.

Os modelos clássicos de xG usam apenas atributos da própria finalização – distância, ângulo de visão da baliza, parte do corpo. Quando incorporam os demais jogadores, fazem-no por meio de atributos desenhados à mão: distância do goleiro, número de defensores na linha do chute, pressão sobre o chutador. Cada um desses atributos é uma hipótese humana sobre o que importa numa finalização.

Dáí a pergunta que orienta este trabalho:

Um modelo que trata **cada jogador como um token** e usa *self-attention* aprende sozinho a geometria de interação que hoje exige engenharia manual de atributos?

A pergunta é interessante porque ambas as respostas são informativas. Se a resposta for afirmativa, a engenharia manual de atributos de interação torna-se dispensável. Se for negativa, isso indica que a informação relevante está *por jogador* e não *entre jogadores* – um resultado que contraria a intuição de que futebol é um jogo de interações.

1.1. Trabalhos relacionados

Modelos de xG baseados em atributos do chute e em atributos manuais de interação estão bem estabelecidos [Rathke 2017, Anzer and Bauer 2021, Mead et al. 2023, Iapteff et al. 2025], e Robberechts e Davis [Robberechts and Davis 2020] mostram como o volume de dados necessário cresce com a complexidade do modelo. O uso de aprendizado profundo sobre as posições de todos os jogadores também já foi explorado: Wang et al. [Wang et al. 2024] aplicam aprendizado geométrico sobre um grafo de jogadores em escanteios, e Fernández et al. [Fernández et al. 2021] avaliam o valor instantâneo da posse com redes profundas sobre dados de rastreamento.

Não foi localizado, contudo, trabalho revisado por pares que aplique *self-attention* sobre *freeze-frames* tratando cada jogador como um token para a estimativa de xG. É essa a lacuna que este trabalho explora.

1.2. Definição formal

Cada finalização é um par (cena, desfecho). A cena é um **conjunto** de até 22 jogadores, cada um descrito por um vetor de atributos geométricos; o desfecho é binário. O objetivo é aprender uma função que mapeia o conjunto em uma probabilidade no intervalo $[0, 1]$.

A propriedade que define o problema é a **invariância à permutação** [Zaheer et al. 2017, Lee et al. 2019]: a ordem em que os jogadores

são listados não carrega informação e, portanto, embaralhá-la não pode alterar a previsão. Isso distingue a tarefa de problemas sequenciais e justifica a ausência de *positional encoding* (Seção 2.3).

2. Abordagem

2.1. Dados

Utilizamos a StatsBomb Open Data [StatsBomb 2026], base pública sob licença de uso não comercial com atribuição. Para cada finalização, a base registra o *freeze-frame*: as coordenadas (x, y) de todos os jogadores visíveis no instante do chute, com seus papéis (companheiro, adversário, goleiro) e o desfecho do lance [StatsBomb 2021]. Após excluir pênaltis e lances sem *freeze-frame*, restam 99.746 finalizações de 3.961 partidas em 80 competições-temporada, com taxa de gol de 10,26%. A base foi baixada do ramo `master` em 03/07/2026; como esse ramo recebe novas competições ao longo do tempo, a data é parte da especificação do conjunto.

Limitações declaradas dos dados

- O *freeze-frame* fornece **posição, mas não velocidade nem direção**. Um defensor parado e outro em corrida de recuperação são indistinguíveis para o modelo. A velocidade do chutador é atributo usado na literatura que dispõe de rastreamento [Anzer and Bauer 2021, Lucey et al. 2015], e está fora de alcance aqui.
- **30,7% das finalizações vêm de competições femininas** e cerca de 37% de apenas quatro temporadas 2015/16 de ligas europeias. Tratá-las conjuntamente não se justifica pela semelhança das taxas de gol (10,4% contra 10,2%) – taxa marginal igual não implica relação condicional igual. A justificativa é empírica e está na Seção 3.4: a conclusão do trabalho se mantém, com intervalo que não cruza zero, em cada um dos quatro recortes avaliados.
- A média é de **13,1 jogadores visíveis por cena**, não 22. O mascaramento das posições vazias é, portanto, o caso comum e não a exceção.

2.2. Representação: o jogador como token

Cada cena é convertida em um conjunto de até 22 tokens (o chutador e os jogadores do *freeze-frame*), cada um com 14 atributos: geometria absoluta, geometria **relativa ao chutador e à linha do chute** (projeção sobre a linha, distância perpendicular, presença no triângulo formado com os postes) e indicadores de papel.

A escolha dos atributos relativos é deliberada: eles informam a cada token sua própria relação com a finalização, sem codificar relações *entre* jogadores. Ambos os modelos recebem exatamente o mesmo tensor de entrada.

Uma consequência dessa escolha precisa ser declarada. Entre os 14 atributos está um indicador binário de que o jogador se encontra no triângulo formado pelo chutador e os postes – isto é, a informação “este jogador está no caminho do chute” **é fornecida ao modelo**, por jogador. Trata-se de uma relação entre o jogador, o chutador e a meta, calculada no pré-processamento e entregue pronta. Isso torna a comparação entre Deep Sets e Transformer mais conservadora do que aparenta: a geometria de obstrução está disponível aos dois, e o Deep Sets pode agregá-la por *pooling*. O que a atenção pode acrescentar é apenas a *ponderação contextual* dessa pista, não sua descoberta.

2.3. Arquitetura

Encoder Transformer [Vaswani et al. 2017] compacto: 2 camadas, 4 cabeças, dimensão 48, token [CLS], **sem *positional encoding*** e com máscara de *padding* nas posições sem jogador. Saída sigmoide. Implementação em PyTorch.




Figura 1. Da cena ao xG. Cada jogador do *freeze-frame* torna-se um token de 14 atributos; um token aprendido [CLS] agrega a informação e alimenta a saída sigmoide. A ausência de *positional encoding* torna a previsão invariante a permutação dos jogadores.

A Figura 1 resume o fluxo.

2.4. Protocolo experimental

Escada de *baselines*. Cada degrau acrescenta exatamente uma capacidade, de modo que a diferença entre degraus atribui o mérito a um componente específico:

Tabela 1. Escada de modelos. Cada degrau acrescenta uma única capacidade.

Modelo	O que acrescenta
B1 Regressão logística: distância, ângulo, cabeceio	o xG “de livro”
B2 B1 + atributos manuais de interação	interação feita à mão
DS Deep Sets [Zaheer et al. 2017] sobre os tokens	informação por jogador
TF Transformer sobre os mesmos tokens	interação aprendida

Os atributos do *baseline* B2 replicam a literatura de xG. A distância e o ângulo de visão da baliza são os dois preditores clássicos, e sua combinação estima xG melhor do que cada um isoladamente [Rathke 2017]. A parte do corpo aparece em praticamente todos os modelos recentes [Anzer and Bauer 2021, Mead et al. 2023]. Os atributos de interação – distância do goleiro ao gol, se o goleiro está na linha do chute, número de defensores na trajetória e distância ao adversário mais próximo – são os mesmos adotados por Anzer e Bauer [Anzer and Bauer 2021] sobre dados posicionais sincronizados e por Iapteff et al. [Iapteff et al. 2025] sobre dados abertos da StatsBomb.

O paralelo com este último é direto: Iapteff et al. [Iapteff et al. 2025] selecionaram, por seleção sequencial, exatamente **sete** atributos, e o conjunto obtido coincide quase termo a termo com o do B2. Uma diferença é que a posição relativa do goleiro é aqui codificada de forma *contínua* (o desvio perpendicular em relação à linha chutador–gol), enquanto aquele trabalho usa um indicador binário – uma generalização do atributo consagrado.

Três atributos da literatura ficaram **de fora** do B2, e a omissão é declarada: o *padrão de jogo*, o *tipo de ação anterior* e o “melhor ângulo” livre de obstrução [Iapteff et al. 2025, Mead et al. 2023, Lucey et al. 2015]. Manteve-se o B2 restrito aos atributos puramente geométricos porque esse é o mesmo espaço de informação disponível aos modelos neurais – caso contrário a comparação deixaria de ser justa.

A comparação decisiva na Tabela 1 é **TF contra DS**: ambos recebem exatamente os mesmos tokens, e apenas o Transformer pode comparar jogadores entre si.

Duas ressalvas sobre o quanto a escada de fato isola. Primeira: o Transformer possui **38.737** parâmetros contra **10.273** do Deep Sets – 3,8 vezes mais –, de modo que a diferença entre os dois não isola a atenção, mas sim “atenção mais capacidade”. Um controle com Deep Sets de capacidade equiparada foi conduzido e é apresentado na Seção 3.4. Segunda: o degrau B2→DS acrescenta simultaneamente a *cena completa* e a *não-linearidade*, pois o B2 é linear. Parte do salto atribuído à representação por token é, portanto, atribuível apenas à classe de modelo, e a separação exigiria um *baseline* não-linear sobre os mesmos sete atributos manuais.

Divisão dos dados por partida (70/15/15). Finalizações da mesma partida compartilham time, adversário e contexto tático; separá-las entre treino e teste inflaria as métricas por vazamento.

Métricas. AUC (ordenação), *log loss*, **Brier score** [Brier 1950] e **curva de calibração** [Niculescu-Mizil and Caruana 2005] (qualidade da probabilidade). Como xG é uma probabilidade e não um *ranking*, o Brier é a métrica de decisão; a AUC o acompanha para distinguir “ordena bem” de “acerta o valor”.

Significância. As diferenças entre modelos são avaliadas por *bootstrap* pareado **agrupado por partida**: reamostram-se partidas, não finalizações, porque chutes do mesmo jogo são correlacionados e reamostrá-los individualmente produziria intervalos de confiança estreitos demais.

3. Resultados

3.1. Escada de *baselines*

A Tabela 2 apresenta o desempenho dos quatro modelos. Cada degrau acrescenta uma única capacidade, de modo que a diferença entre linhas consecutivas atribui o mérito a um componente específico.

O padrão é direto: fornecer a cena inteira ao modelo supera resumi-la em atributos manuais – mas **menos do que a comparação com o B2 linear sugere**. O B2-GBM, que usa exatamente os mesmos sete atributos manuais e difere apenas na classe de modelo, alcança AUC 0,8069 e Brier 0,07710. Da distância entre o B2 e o Deep Sets, a **não-linearidade sozinha explica 54,5 % em AUC e 64,6 % em Brier**.

A representação por token, portanto, agrega valor real, porém aproximadamente *metade* do que uma escada iniciada em um *baseline* linear indicaria. Registre-se ainda que o B2-GBM é o **modelo mais bem calibrado do estudo** (ECE 0,0018): um *gradient boosting* sobre sete atributos construídos manualmente entrega a melhor calibração entre todos os modelos avaliados.

Tabela 2. Desempenho no conjunto de teste (14.935 finalizações), divisão por partida. Modelos neurais: combinação de 5 sementes. ECE = erro de calibração esperado, em decis de xG previsto. B2-GBM usa os mesmos sete atributos do B2, mudando apenas a classe de modelo.

Modelo	AUC	Brier	ECE
B1 – logística	0,7653	0,08237	0,0076
B2 – logística + interação	0,7961	0,07846	0,0035
B2-GBM – mesmos atributos, não-linear	0,8069	0,07710	0,0018
DS – Deep Sets (tokens)	0,8160	0,07635	0,0070
TF – Transformer (tokens)	0,8162	0,07579	0,0043

3.2. Calibração

A Tabela 2 revela um padrão que a AUC isoladamente esconde: **os dois *baselines* de atributos manuais são os mais bem calibrados do conjunto** (ECE 0,0018 no B2-GBM e 0,0035 no B2), apesar de terem Brier pior que os modelos neurais. Estes apresentam Brier melhor e calibração pior.

Não há contradição. O Brier decompõe-se em *calibração* – as probabilidades correspondem às frequências observadas? – e *refinamento* – o modelo separa bem os casos? Os modelos neurais vencem no refinamento e perdem na calibração, com saldo positivo. As curvas de confiabilidade dos quatro modelos estão no repositório.

A recalibração não ajuda

Diante da diferença de ECE entre o B2 e os modelos neurais, testou-se recalibrar as saídas por *Platt scaling* e por regressão isotônica, ajustando o calibrador no conjunto de **validação** e avaliando no de teste – ajustá-lo no teste reproduziria o vazamento que a divisão por partida existe para evitar.

Tabela 3. Efeito da recalibração. Calibrador ajustado na validação, avaliação no teste, semente 0.

Modelo	Variante	Brier	ECE
DS	sem calibração	0,07653	0,0069
DS	Platt	0,07652	0,0055
DS	isotônica	0,07682	0,0065
TF	sem calibração	0,07612	0,0076
TF	Platt	0,07613	0,0069
TF	isotônica	0,07633	0,0057

O resultado é negativo: o *Platt scaling* é neutro em Brier e a regressão isotônica o *piora* em ambos os modelos. Com evento raro e 15 mil pontos de validação, a flexibilidade da isotônica ajusta-se a ruído que não se repete no teste. Ambas reduzem modestamente o ECE, devolvendo em refinamento o que ganham em calibração.

A explicação é que os modelos já saem calibrados: a entropia cruzada é uma regra de pontuação própria, de modo que otimizá-la já posiciona as probabilidades na escala correta [Niculescu-Mizil and Caruana 2005]. Os resultados reportados neste trabalho são, portanto, do modelo **sem recalibração**.

Calibração agregada por partida

O teste mais próximo do uso real da métrica não é por finalização, e sim por partida: somando o xG previsto de todos os chutes de um jogo, o total corresponde aos gols efetivamente marcados?

Sobre as 595 partidas de teste, o Transformer prevê **1591,2** de xG total contra **1571** gols observados – viés de **+1,3 %**. O Deep Sets fica em **+1,5 %**. O erro médio de 1,16 gol *por partida* não indica falha do modelo: uma partida tem poucos gols e forte componente aleatório, e é precisamente por isso que o xG é uma métrica de agregação. O diagrama por partida, disponível no repositório, mostra o padrão esperado: a média por faixa acompanha a diagonal na região densa e regride ao centro nos extremos, onde há poucas partidas.

3.3. A atenção acrescenta algo? (questão central)

Deep Sets e Transformer recebem exatamente os mesmos tokens; apenas o segundo compara jogadores entre si. A diferença entre eles isola o valor da atenção par a par. Foram treinadas 5 sementes de cada modelo, com seleção por Brier de validação.

Tabela 4. Transformer contra Deep Sets, 5 sementes cada. Teste pareado por *bootstrap* agrupado por partida (2.000 reamostras).

	Brier	AUC
<i>Modelos individuais</i> (média $\pm$ dp das 5 sementes)		
DS	$0,07655 \pm 0,00007$	$0,8146 \pm 0,0007$
TF	$0,07624 \pm 0,00005$	$0,8141 \pm 0,0009$
Diferença (TF – DS)	$-0,00031$	$-0,00058$
<i>Combinação das 5 sementes</i> (média das probabilidades)		
DS	$0,07635$	$0,8160$
TF	$0,07579$	$0,8162$
Diferença (TF – DS)	$-0,00056$	$+0,00024$
IC 95% (partidas)	$[-0,00081; -0,00031]$	$[-0,00148; +0,00199]$
valor- <i>p</i>	$< 0,001$	$0,797$

A Tabela 4 apresenta o resultado, que é uma dissociação limpa entre as duas métricas:

A atenção par a par melhora a qualidade da probabilidade, mas não a capacidade de ordenar as finalizações.

O sinal favorece o Transformer em Brier nas cinco sementes, e a distribuição *bootstrap* da diferença entre as combinações situa-se integralmente à esquerda de zero.

Em AUC a diferença é indistinguível de ruído ($p = 0,797$) e, entre modelos individuais, favorece o *Deep Sets*.

Três ressalvas impedem tratar o efeito como estabelecido.

Primeira, **o teste condiciona em uma combinação específica de sementes**. Ele reamostra partidas, propagando a variabilidade dos dados, mas não a variabilidade de *inicialização*. A diferença entre modelos individuais ($-0,00031$) é pouco mais da metade da diferença entre as combinações ($-0,00056$): parte do efeito anunciado é o Transformer beneficiar-se mais da média de sementes – suas previsões são mais dispersas entre inicializações –, e não a atenção. Refazendo o mesmo teste **semente a semente**, o intervalo de confiança cruza zero nas **cinco** inicializações (menor valor- p : $0,053$). A significância, portanto, existe para o conjunto combinado, não para um modelo individual. Em contrapartida, o sinal favorece o Transformer em 5 de 5 sementes, o que sob um teste de sinal corresponderia a $p \approx 0,06$: sugestivo, e coerente com um efeito real porém pequeno demais para ser detectado por uma única inicialização com 595 partidas.

Segunda, **o mecanismo alegado depende do recorte**. Na combinação das sementes o Transformer é o mais bem calibrado (ECE $0,0043$ contra $0,0070$); nos modelos individuais a ordem *inverte* ($0,0082$ contra $0,0074$). Atribuir o ganho à calibração é, portanto, sustentável apenas para o conjunto combinado.

Terceira, **a magnitude é pequena**. Tomando a taxa média de gol como referência trivial, o Brier de referência no teste é $0,0941$; a perícia do Deep Sets sobre essa referência é de $18,9\%$ e a do Transformer, $19,5\%$. A atenção acrescenta cerca de meio ponto percentual de perícia – aproximadamente 3% da capacidade preditiva do modelo. O efeito é direcionalmente consistente, mas sua relevância prática é discutível.

Some-se a isso a diferença de capacidade declarada na Seção 2.4: o resultado honesto é que **a atenção, somada a 3,8 vezes mais parâmetros, produz um ganho pequeno e consistente na qualidade da probabilidade, e nenhum na ordenação**.

3.4. O ganho é atenção ou capacidade?

O Transformer possui 3,8 vezes os parâmetros do Deep Sets, de modo que a comparação anterior não isola a atenção. Para separar os dois efeitos, treinou-se um Deep Sets com dimensão 96, que totaliza **38.977** parâmetros contra 38.737 do Transformer – equiparação de $100,6\%$ –, sob protocolo idêntico e com as mesmas cinco sementes.

A Tabela 5 **refuta** a explicação por capacidade. Equiparar os parâmetros não aproximou o Deep Sets do Transformer: afastou. A vantagem do Transformer *crece* de $-0,00056$ para $-0,00073$ quando a comparação se torna justa, e o intervalo de confiança não cruza zero.

Há ainda um achado próprio: **ampliar a capacidade do Deep Sets o piora** ($+0,00018$ de Brier, com intervalo estritamente positivo). Sem o mecanismo de atenção, os parâmetros adicionais não encontram estrutura a explorar e o modelo sobreajusta.

Tabela 5. Controle de capacidade. Cinco sementes por modelo; *bootstrap* pareado agrupado por partida.

Modelo	Parâmetros	Brier	AUC
DS original (dim 48)	10.273	$0,07655 \pm 0,00008$	$0,8146 \pm 0,0007$
DS largo (dim 96)	38.977	$0,07670 \pm 0,00005$	$0,8131 \pm 0,0010$
TF (dim 48)	38.737	$0,07624 \pm 0,00006$	$0,8141 \pm 0,0011$
<i>Diferenças de Brier entre combinações das 5 sementes</i>			
TF – DS largo		$-0,00073$	IC $[-0,00101; -0,00045]$
TF – DS original		$-0,00056$	IC $[-0,00081; -0,00031]$
DS largo – DS original		$+0,00018$	IC $[+0,00002; +0,00034]$

Tampouco é a ReLU terminal do Deep Sets

Resta uma explicação arquitetural que não envolve atenção. O ϕ do Deep Sets *termina* em ReLU, de modo que toda representação por jogador é não negativa e a cabeça linear recebe um vetor restrito ao ortante positivo; a saída do [CLS] vem do fluxo residual e tem sinal livre. Se fosse essa a origem da diferença, a comparação estaria medindo “atenção mais liberdade de sinal” – e o controle de capacidade não a detectaria, pois ampliar a dimensão não remove a restrição. Treinou-se então um Deep Sets idêntico *exceto* pela remoção dessa ReLU, com os mesmos 10.273 parâmetros e as mesmas três sementes, usadas também para refazer as combinações de referência.

A remoção não aproximou o Deep Sets do Transformer: piorou-o. O Brier médio passa de 0,07654 para 0,07664 e a AUC cai de 0,8145 para 0,8131, com as três sementes na mesma direção nas duas métricas. Entre as combinações, a diferença de Brier é de $+0,00012$, IC $[-0,00008; +0,00032]$ – sem indício de ganho –, enquanto a vantagem do Transformer permanece com intervalo estritamente negativo ($-0,00067$, IC $[-0,00095; -0,00040]$). A restrição de sinal não explica a diferença entre as arquiteturas.

A conclusão vale em todos os recortes

A vantagem do Transformer foi reavaliada em quatro subconjuntos do teste, e em nenhum o intervalo de confiança cruza zero: futebol feminino ($-0,00086$, 4.443 finalizações), futebol masculino ($-0,00043$, 10.492), temporadas 2015/16 ($-0,00053$, 6.070) e demais competições ($-0,00058$, 8.865). O efeito é cerca de duas vezes maior no futebol feminino, o que se registra sem investigar.

3.5. Generalização para uma competição não vista

Os quatro recortes acima provêm do mesmo conjunto de 80 competições-temporada: medem robustez interna, não generalização para um torneio não observado. Para medir esta última, a *Premier League* 2015/16 foi retirada por inteiro do treino e da validação e usada como teste – 9.817 finalizações em 380 partidas, com 914 gols –, com asserção no código de que nada vazou.

O Brier não é comparável entre os dois testes, porque depende da taxa de gol do

conjunto: a competição retirada tem 9,31 % de gols contra 10,52 % do teste habitual, de modo que qualquer modelo obtém Brier mais baixo nela. A comparação usa portanto a **perícia** sobre a taxa média de gol, $1 - \text{Brier}/[p(1 - p)]$, que é adimensional.

Tabela 6. Generalização para a *Premier League* 2015/16, inteiramente fora do treino. “Dentro” é o teste habitual, de partidas sorteadas.

Modelo	Perícia		AUC	
	Dentro	Fora	Dentro	Fora
B1	12,5 %	9,3 %	0,7653	0,7553
B2	16,6 %	13,1 %	0,7961	0,7838
Deep Sets	18,9 %	15,2 %	0,8160	0,7981
Transformer	19,5 %	15,5 %	0,8162	0,7969

A Tabela 6 sustenta três leituras.

Primeira, **todos os modelos perdem cerca de um quinto da perícia** fora da distribuição, e em proporção semelhante: nenhuma arquitetura se mostra especialmente frágil, mas os números das seções anteriores são otimistas para uma liga-temporada nova.

Segunda, **a calibração agregada não se degrada**. O xG somado do Transformer é de 908,7 contra 914 gols observados – viés de $-0,6\%$, melhor do que o $+1,3\%$ obtido dentro da distribuição. O modelo perde capacidade de *ordenar* finalizações de uma liga que não viu, e mantém a de estimar *quanto* vale o conjunto delas, que é o uso mais comum do xG.

Terceira, **a vantagem do Transformer não se sustenta fora da distribuição**: $-0,00024$, IC $[-0,00063; +0,00016]$, $p = 0,251$. Duas explicações são compatíveis, e este trabalho não decide entre elas: o efeito pode ter encolhido (de $-0,00056$ para $-0,00024$) ou o teste pode ter perdido poder, já que 9.817 finalizações são dois terços das 14.935 do teste habitual. Registre-se que aqui o Transformer foi treinado com duas sementes e não três – a máquina suspendia durante a madrugada e o tempo de parede inviabilizou a terceira. É a única assimetria de protocolo do trabalho, e favorece o Deep Sets.

3.6. O que a atenção está olhando

O resultado anterior mostra *que* a atenção contribui. Resta saber *como*. Mediu-se a atenção que o token [CLS] dirige a cada jogador, normalizada pela atenção que ele receberia sob distribuição uniforme: o valor 1,0 indica “observado como um jogador qualquer da cena”.

O ordenamento da Tabela 7 – bloqueador, goleiro, adversário distante, companheiro – reproduz a hierarquia que a literatura de xG codifica manualmente.

É preciso ser preciso sobre o que isso demonstra. Como declarado na Seção 2.2, o indicador “dentro do triângulo do chute” é **um atributo de entrada**, fornecido por jogador. O modelo não descobriu quem está no caminho do chute: essa informação lhe foi dada. O que a Tabela 7 mostra é que o modelo aprendeu a **ponderar** essa pista – atribuindo peso 2,76 vezes maior a quem a possui –, em vez de tratar todos os jogadores

Tabela 7. Razão de atenção por papel na cena. Transformer, semente 0, média das 2 camadas e 4 cabeças, sobre 14.935 finalizações.

Papel na cena	Razão média	Mediana
Bloqueador (adversário na linha do chute)	2,76×	2,45×
Goleiro adversário	1,38×	1,21×
Outro adversário	0,92×	0,96×
Companheiro	0,75×	0,74×

como igualmente relevantes. É um resultado mais modesto do que “a atenção redescobriu a geometria de interação”, e é o que os dados sustentam.

Isso também oferece a explicação mais econômica para o Deep Sets igualar o Transformer em ordenação: se a geometria de obstrução chega pronta em cada token, um agregador por *pooling* já a aproveita, e resta pouco para a atenção acrescentar.

Três ressalvas adicionais. A análise é **correlacional**: mostra onde a atenção se concentra, não que dela decorra o ganho em Brier. Os pesos da segunda camada operam sobre representações já contextualizadas, de modo que “atenção alta” não equivale a “importância” – ponto amplamente discutido na literatura sobre atenção como explicação. E os valores provêm de **uma única semente**, com média sobre 2 camadas e 4 cabeças, o que pode cancelar papéis distintos entre elas.

Ablação causal

Para ir além da correlação, a atenção que o [CLS] dirige a um grupo foi **suprimida** – zerada e com a linha renormalizada, de modo que o modelo continua vendo uma distribuição válida, porém proibido de observar aqueles jogadores. Mede-se então a degradação do Brier. O controle é essencial: suprimir jogadores sempre causa alguma perda, e a pergunta é se suprimir *estes* causa mais.

Tabela 8. Ablação da atenção do [CLS]. Transformer, semente 0, 14.935 finalizações.

Grupo suprimido	Brier	Δ vs. intacto	AUC
nenhum (referência)	0,07612	—	0,8159
Bloqueadores	0,07701	+0,00088	0,8064
Goleiro	0,07671	+0,00059	0,8145
Controle: sorteados, mesma quantidade	0,07624	+0,00011	0,8148
Companheiros	0,07618	+0,00005	0,8153
Todos os jogadores	0,10194	+0,02582	0,7951

Na Tabela 8, suprimir os bloqueadores custa +0,00088 de Brier – **7,9 vezes** o custo de suprimir a mesma quantidade de jogadores sorteados (+0,00011). A AUC cai de 0,8159 para 0,8064, contra 0,8148 no controle. A evidência, portanto, **não é apenas correlacional**: o desempenho depende causalmente dessa atenção.

Dois aspectos reforçam a leitura. O efeito (+0,00088) é *maior* que a própria vantagem do Transformer sobre o Deep Sets equiparado (0,00073), o que indica mecanismo estruturante e não marginal. E companheiros custam praticamente nada (+0,00005) – coerente, pois em uma finalização quem obstrui são os adversários.

Permanece a limitação de **uma única semente**, a única cujos pesos foram preservados, e a supressão atua nas duas camadas simultaneamente.

3.7. Estudo de caso: Eurocopa 2024

A proposta deste trabalho previa a Copa do Mundo de 2026 como estudo de caso. Em consulta à StatsBomb Open Data em 09/08/2026 verificou-se que a competição ainda não havia sido publicada – a mais recente disponível é a Eurocopa Feminina de 2025. O estudo de caso foi então conduzido sobre a **Eurocopa 2024**, o torneio de seleções mais recente da base.

Utilizaram-se apenas as 166 finalizações do torneio que caíram no conjunto de **teste** (6 partidas, 15 gols). Trata-se de **análise qualitativa**, não de avaliação: 15 gols é amostra pequena demais para sustentar conclusão quantitativa, papel que cabe à Seção anterior.




Figura 2. Três cenas reais da Eurocopa 2024. O tamanho de cada jogador é proporcional à atenção que o token [CLS] lhe dirige. Os casos foram selecionados por critério automático, não manualmente.

Os três casos da Figura 2 mostram o modelo **deslocando o foco conforme a cena** – ponderando de modo distinto jogadores que recebem os mesmos tipos de atributo. No chute de fora da área com o goleiro na trajetória, o goleiro concentra sozinho 32 % de toda a atenção dirigida aos jogadores, e o xG previsto é 0,035. Na finalização dentro da área com defensores atravessados, a atenção migra para os bloqueadores (49 %) e o goleiro cai para 5 %; apesar da proximidade da meta, o xG é de apenas 0,117. No lance de maior xG do torneio (0,750), dentro da pequena área e sem obstrução, a atenção *dispersa-se*: nenhum jogador é determinante porque nada interfere na trajetória.

O contraste entre o segundo e o terceiro casos resume o argumento do trabalho em uma imagem: mesma região do campo, xG seis vezes menor, e a diferença é visível na distribuição da atenção.

4. Lições Aprendidas

4.1. O que funcionou

Escalar os dados resolveu o que aparentava ser um problema de arquitetura. Na prova de conceito, com 6.347 finalizações, os modelos neurais alcançavam AUC de aproximadamente 0,71 – *abaixo* do *baseline* com atributos manuais (0,736). Com 99.746 finalizações, ambos superaram esse *baseline* com folga. A conclusão precipitada de que “a arquitetura não serve” teria sido incorreta.

A escolha da métrica alterou a conclusão científica. A implementação inicial reportava apenas AUC. Sob essa métrica, o Transformer é ligeiramente *pior* que o Deep Sets, e a conclusão seria que a atenção não contribui – um resultado negativo falso. Foi a adoção do Brier como critério de decisão, motivada pelo fato de xG ser uma probabilidade e não um ordenamento, que tornou o efeito visível. Uma decisão metodológica, tomada antes dos experimentos, determinou o que se pôde concluir.

4.2. O que não funcionou

Trocar a métrica de seleção sem reescalar a tolerância. Ao migrar o critério de parada antecipada de AUC para Brier, manteve-se o limiar de melhoria em 10^{-6} absoluto. Como a AUC opera em torno de 0,81 e o Brier em torno de 0,076, o mesmo valor absoluto tornou-se relativamente dez vezes mais restritivo: praticamente qualquer flutuação era contabilizada como melhoria, a paciência não era acionada e o treino prosseguia até a última época, selecionando um estado já sobreajustado. O critério concebido para otimizar o Brier produziu Brier *pior* (0,07646 contra 0,07627 na mesma semente). A correção para tolerância relativa recuperou o desempenho e reduziu o tempo de treino em cerca de 30%.

Recalibrar não melhorou nada. Ao observar que o *baseline* de regressão logística apresentava melhor ECE que os modelos neurais, previu-se que recalibrar traria ganho fácil em Brier. Não trouxe: o *Platt scaling* foi neutro e a regressão isotônica piorou o Brier dos dois modelos (Tabela 3). A hipótese estava errada, e a razão é instrutiva – treinar com entropia cruzada já produz probabilidades calibradas, restando pouco a corrigir.

Duas sementes não bastam, e a estabilidade aparente engana. Com 2 sementes, o Deep Sets apresentou amplitude de AUC de 0,0001, sugerindo extraordinária estabilidade. Com 5 sementes, a amplitude foi de 0,0019 – dezenove vezes maior – e a conclusão sobre sobreposição de faixas, obtida com a amostra menor, mostrou-se equivocada.

Afirmar que o modelo redescobriu algo que eu havia lhe fornecido. A primeira versão deste relatório sustentava que a concentração de atenção sobre os bloqueadores demonstrava redescoberta autônoma da geometria de interação, “sem jamais ter recebido essa informação como atributo”. A afirmação é **falsa**: o indicador de presença no triângulo do chute é o décimo atributo de cada token. O erro sobreviveu a uma verificação automática que confere cada número do texto contra o registro do experimento que o produziu – porque essa verificação garante que os números estão *transcritos* corretamente, não que estão sendo *interpretados* corretamente. Nenhuma automação substitui a leitura crítica do próprio código.

A escada isolava menos do que eu afirmava. O Transformer tem 3,8 vezes mais parâmetros que o Deep Sets, e o degrau B2→DS mistura representação com não-linearidade. Ambos os confundimentos estavam presentes desde o desenho do protocolo e só foram percebidos na revisão final. O primeiro foi então medido (Seção 3.4) e revelou-se favorável à conclusão – mas isso é sorte, não método: se a capacidade explicasse o efeito, o trabalho teria sustentado por semanas uma conclusão infundada. O controle deveria ter sido parte do desenho, não da correção.

4.3. O que eu faria diferente

Verificaria a disponibilidade dos dados antes de prometé-los: a proposta previa a Copa do Mundo de 2026 como estudo de caso, mas a competição não havia sido publicada na base pública até a data de entrega. Registraria previsões e pesos dos modelos em disco desde o primeiro experimento – sua ausência obrigou a retreinamentos que consumiram horas. E adotaria as métricas de calibração desde o início, em vez de reportar AUC e descobrir tardiamente que ela é cega justamente para a dimensão que define o problema.

Disponibilidade do código

Todo o código, a documentação de decisões e o registro de experimentos estão em <https://github.com/vinisique/xg-set-transformer>.

Referências

- Anzer, G. and Bauer, P. (2021). A goal scoring probability model for shots based on synchronized positional and event data in football (soccer). *Frontiers in Sports and Active Living*, 3:624475.
- Brier, G. W. (1950). Verification of forecasts expressed in terms of probability. *Monthly Weather Review*, 78(1):1–3.
- Fernández, J., Bornn, L., and Cervone, D. (2021). A framework for the fine-grained evaluation of the instantaneous expected value of soccer possessions. *Machine Learning*, 110(6):1389–1427.
- Iapteff, L., Le Coz, S., Rioland, M., Houde, T., Carling, C., and Imbach, F. (2025). Toward interpretable expected goals modeling using Bayesian mixed models. *Frontiers in Sports and Active Living*, 7:1504362.
- Lee, J., Lee, Y., Kim, J., Kosiorek, A. R., Choi, S., and Teh, Y. W. (2019). Set transformer: A framework for attention-based permutation-invariant neural networks. In *International Conference on Machine Learning (ICML)*.
- Lucey, P., Bialkowski, A., Monfort, M., Carr, P., and Matthews, I. (2015). “Quality vs Quantity”: Improved shot prediction in soccer using strategic features from spatiotemporal data. In *Proceedings of the 9th Annual MIT Sloan Sports Analytics Conference*.
- Mead, J., O’Hare, A., and McMenemy, P. (2023). Expected goals in football: Improving model performance and demonstrating value. *PLOS ONE*, 18(4):e0282295.
- Niculescu-Mizil, A. and Caruana, R. (2005). Predicting good probabilities with supervised learning. In *International Conference on Machine Learning (ICML)*.

- Rathke, A. (2017). An examination of expected goals and shot efficiency in soccer. *Journal of Human Sport and Exercise*, 12(Proc2).
- Robberechts, P. and Davis, J. (2020). How data availability affects the ability to learn good xG models. In *Machine Learning and Data Mining for Sports Analytics (MLSA)*, Communications in Computer and Information Science, pages 17–27. Springer.
- StatsBomb (2021). StatsBomb data case studies: Freeze frames and defender locations.
- StatsBomb (2026). Statsbomb open data. <https://github.com/statsbomb/open-data>. Acesso em 09 ago. 2026.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*.
- Wang, Z., Veličković, P., Hennes, D., Tomašev, N., Prince, L., Kaisers, M., Bachrach, Y., and Elie, R. (2024). TacticAI: an AI assistant for football tactics. *Nature Communications*, 15(1):1906.
- Zaheer, M., Kottur, S., Ravanbakhsh, S., Póczos, B., Salakhutdinov, R., and Smola, A. J. (2017). Deep sets. In *Advances in Neural Information Processing Systems (NeurIPS)*.